

¡El problema de que vengas y no vuelvas!

Cómo hacemos posible una mejor experiencia de usuario de nuestros clientes a través del machine learning



El 20% de los clientes de la compañía abandonan debido a múltiples razones.

Frustrana sabe que los clientes se van, **pero no sabe la calidad de clientes que se van.**


Frustrana gasta alrededor del 10% de sus ingresos en equipos de recuperación de clientes de manera masiva

Sin embargo, Frustrana no sabe qué segmentos de clientes valen más la pena recuperar, **ocasionando ineficiencias en clientes de bajo valor**



Problema






A través de **analítica de datos y machine learning**, comparamos una regla de agregación con modelos de ML para comprobar qué acertaba más a la hora de estimar el abandono de los clientes



Creamos **estrategias diferenciadas para el abordaje de cada cliente**, mejorando la métrica estándar de recuperación de clientes




Pensamos en **mejores beneficios para los clientes**, en función de las razones por las cuales tiene alta probabilidad de abandono, y actuamos



Solución







Obtuvimos un modelo de 263 mil personas y comercios para predecir comportamiento de los clientes de Sao Paulo, BR



Generamos una regla que clasifica el riesgo de cada cliente de manera individual



Y luego las segmentamos por valor de ingreso promedio para la compañía



Para generar estrategias hiper personalizadas a nuestros usuarios de más alto valor

Metodología




El 98% de los datos que tenemos pertenecen a Restaurantes



El segmento más popular de clientes hace sus pagos en efectivo



94% de las órdenes se entregan a tiempo




Los días martes y miércoles hay una mayor cantidad de órdenes

- Un cliente aporta US\$116,92 a lo largo de su tiempo como cliente.
- El valor promedio de GMV por compra es de aproximadamente US\$97,23.
- En promedio, un cliente realiza aproximadamente 27.67 compras
- La duración promedio de un cliente (tiempo de registro y última orden) es de aproximadamente 175, 36 días.



Primeros Hallazgos

Valores representados de una sola región de São Paulo.



Una señal importante






:O Otra señal importante

Las operaciones llevadas a cabo con cash son mucho más propensas a errores transaccionales que las operaciones electrónicas




Los clientes churneados tienen un comportamiento de reducción de compras paulatino y no repentino



Otra señal



Los clientes churneados tienen un comportamiento de reducción de compras paulatino y no repentino



Otra señal

El mayor problema de los errores no es el error, sino la reiteración sobre el mismo cliente. Por ejemplo: Llegadas a tiempo, productos faltantes, cancelaciones, entre otros.





**Evitar los strikes 2 y 3 en la
mayor parte de los clientes de
la compañía**

Nuestro objetivo





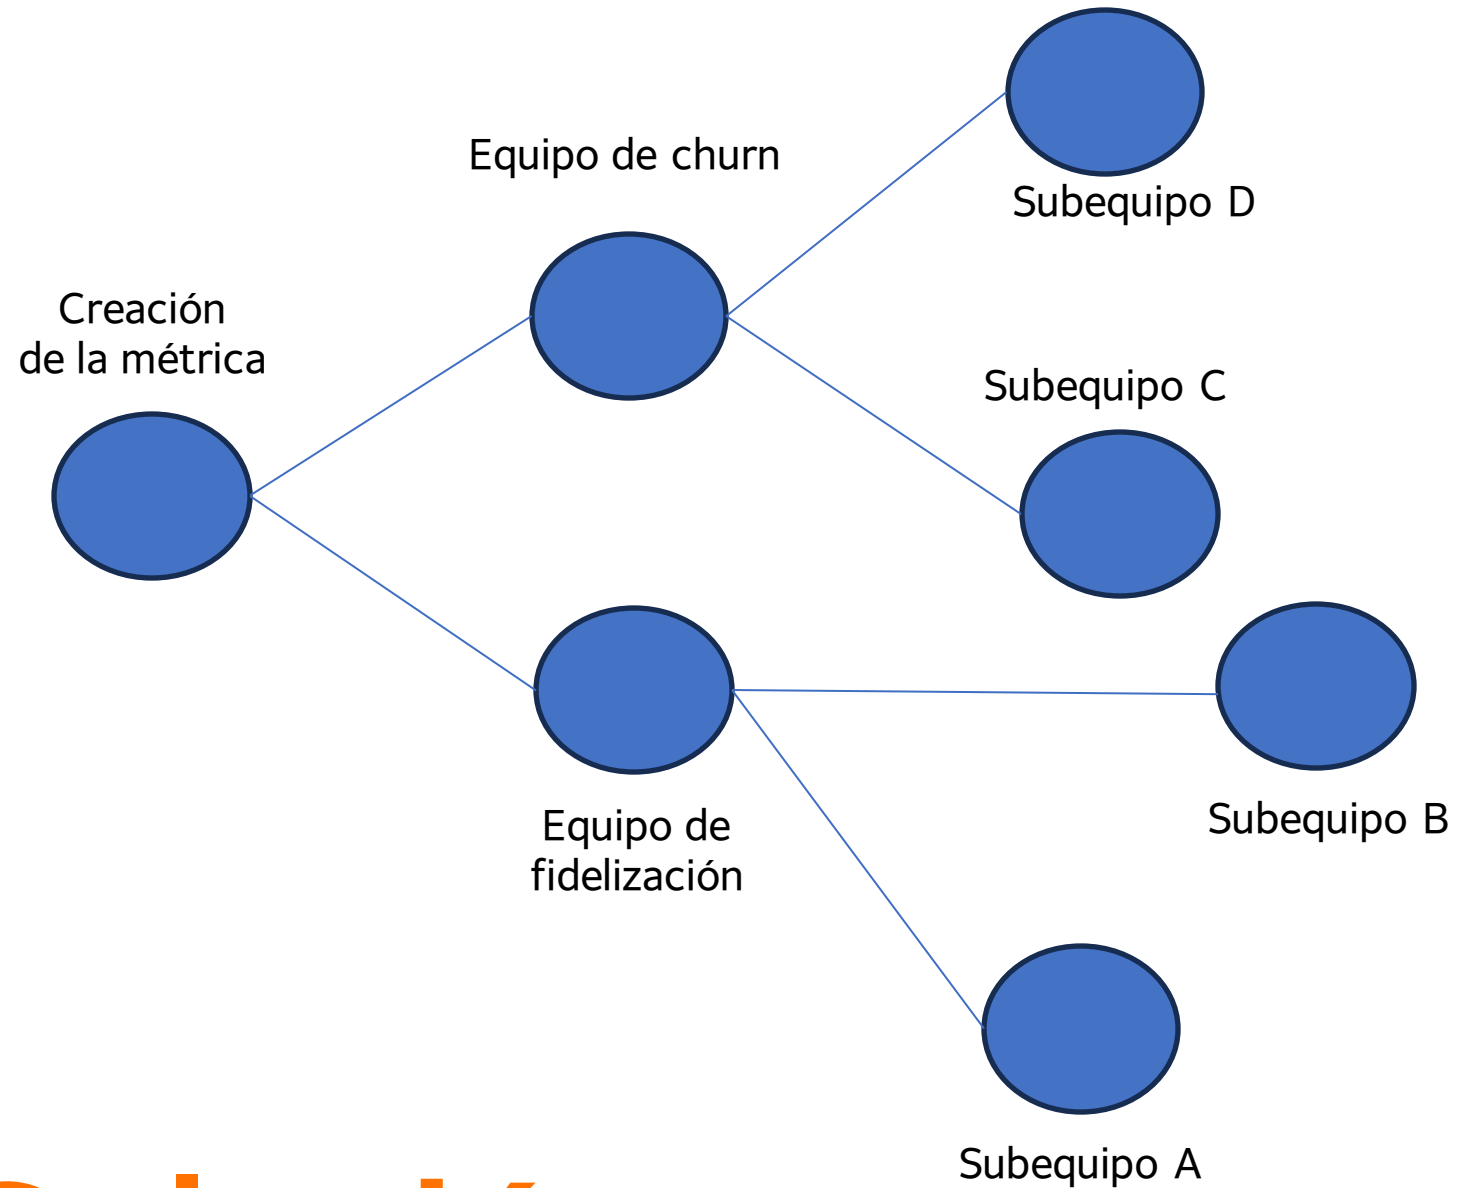
Utilizamos un conjunto de datos anonimizados de transacciones de clientes, enfocándonos en la fecha de cierre de pedidos



Calculamos si un cliente está en riesgo de Churn basado en su frecuencia de compra y la última fecha de compra



Consideramos a un cliente en riesgo si su frecuencia de compra disminuye significativamente




Nuestra Solución



El Resultado

El resultado del grid permite encontrar un modelo que maximiza el Recall y que se ajusta a las necesidades determinadas del negocio



¿Por qué importa el Recall?

Importa porque es supremamente más relevante encontrar un posible cliente churneado dado que lo es que encontrar un cliente en churn que posiblemente no lo sea

Decisión de Negocio

Entrando al modelo



El Resultado

El resultado del grid permite encontrar un modelo que maximiza el Recall y que se ajusta a las necesidades determinadas del negocio



MÉTRICAS RENDIMIENTO	LOGISTIC REG	RANDOM FOREST	SVM	REGLA
Recall	0,77	0,78	0,75	0,96
Sensibilidad	0,83	0,84	0,82	0,81
Especificidad	0,72	0,75	0,69	0,78
F1 Score	0,80	0,77	0,78	0,30

¿Por qué importa el Recall?

Importa porque es supremamente más relevante encontrar un posible cliente churneado dado que lo es que encontrar un cliente en churn que posiblemente no lo sea

Decisión de Negocio

Comparación de modelos



Apalancamos el uso de la herramienta de predicción a múltiples áreas de la compañía



Creamos el Recall más alto para los usuarios y otros usuarios con extrapolación del modelo

Se enviaron alertas de acciones de recuperación para prevenir la ocurrencia de los strikes 2 y 3.

Negocio validará valorización monetaria de las pérdidas recuperadas

Resultados de Negocio



SECCION 3 - Clientes Afectados ft Clientes A Priorizar

% Clientes - Strikes x Drop / Clientes / Country / Weekly

		week	2023-38	2023-39	2023-40	2023-41	2023-42	2023-43	2023-44	2023-45	2023-46	2023-47	2023-48
country	strikes_x_drops												
BR	0 - 0.5		3.43	6.73	7.52	7.19	5.92	5.49	5.99	6.46	6.44	6.14	3.08
	0.5 - 1.0		2.74	2.52	2.92	2.95	1.98	1.97	2.44	2.42	2.74	2.66	1.64
	1.0 - 1.5		0.01	0.01	0.00	0.02	0.01	0.06	0.01	0.02	0.01	0.02	0.01
	1.5 - 2.0		0.05	0.04	0.04	0.04	0.02	0.05	0.04	0.04	0.05	0.02	0.03
	> 2.0		0.03	0.02	0.01	0.00	0.01	0.02	0.00	0.01	0.01	0.01	0.03
	Cero		93.74	90.68	89.51	89.81	92.06	92.42	91.52	91.05	90.76	91.15	95.22
CO	0 - 0.5		2.41	4.89	5.92	4.49	4.33	5.20	5.21	3.59	3.91	3.62	2.63
	0.5 - 1.0		3.85	3.49	4.97	3.17	2.96	4.22	3.53	2.94	3.42	2.90	2.76
	1.0 - 1.5			0.03	0.03	0.02	0.03	0.06	0.02	0.02		0.00	
	1.5 - 2.0		0.07	0.13	0.08	0.07	0.10	0.09	0.09	0.06	0.03	0.03	0.06
	> 2.0			0.02	0.00	0.02	0.01	0.02	0.00	0.02	0.01	0.00	0.01
	Cero		93.68	91.45	89.01	92.25	92.59	90.43	91.18	93.37	92.63	93.44	94.54
	0 - 0.5		2.70	6.72	5.96	5.46	5.14	6.00	4.65	6.29	5.98	6.04	2.70
	0.5 - 1.0		5.77	7.90	7.34	6.89	6.76	8.38	5.32	8.08	7.97	7.99	7.69

Los datos se muestran a partir de los tableros de visualización de Frubana en donde serán dispuestos para el uso de áreas internas.

El software de visualización es Redash

Visualización





Modelo de Churn para clientes de Sao Paulo

